

ANÁLISE PREDITIVA · MACHINE LEARNING · ENOLOGIA

A Ciência por Trás de um Grande Vinho

Indicadores de performance para escalar e sustentar uma produção de qualidade superior

Wine Quality Dataset · Previsão de Qualidade via Química

1.143

amostras analisadas

13,9%

vinhos de alta qualidade

0,657

F1-score · XGBoost

≈ 0,90

ROC-AUC · modelo final

01 · Contexto e Base de Dados

Wine Quality Dataset · Vinhos tintos · 11 variáveis físico-químicas

A avaliação sensorial de um vinho é tradicionalmente cara, demorada e subjetiva, dependente do paladar de especialistas treinados. Este trabalho transforma essa arte em ciência: a partir de 1.143 amostras de vinho tinto — cada uma com 11 variáveis físico-químicas medidas em laboratório — construímos modelos de Machine Learning capazes de prever se um vinho será de Alta Qualidade (nota ≥ 7) ou Baixa/Média Qualidade (nota < 7).

DIMENSÕES INVESTIGADAS

- Análise exploratória — distribuições, outliers e correlações
- Pré-processamento — feature engineering e balanceamento de classes
- Duelo de modelos — Random Forest vs. XGBoost via GridSearchCV
- Interpretação — consenso de importância entre modelos
- Implicações práticas — recomendações para o processo produtivo

1.143

Amostras carregadas

11 + 4

Features originais + engineered

159

Vinhos nota ≥ 7

80 / 20

Split treino / teste

~6:1


Desbalanceamento de classes

INSIGHT

Apenas 13,9% das amostras são de alta qualidade — um problema clássico de classificação desbalanceada. Toda a estratégia de modelagem foi desenhada em torno desse desafio, priorizando F1-score e recall da classe minoritária.

02 · O Que os Dados Revelaram

Perfil químico do vinho de alta qualidade — 1.143 amostras, notas de 3 a 8, sem valores nulos



Álcool

+12%

Principal preditor de qualidade

Acidez volátil

-29%

"Inimiga" da qualidade — aroma de vinagre

Sulfatos

+16%

Conservação e estabilidade

Ácido cítrico

+57%

Frescor e vivacidade

DIAGNÓSTICO

O teor alcoólico é praticamente monotônico em relação à nota: da nota 5 em diante, cada ponto adicional de qualidade acompanha um aumento no álcool médio. A acidez volátil apresenta o comportamento espelhado — cai de forma consistente conforme a nota sobe.

03 · Preparando o Terreno

Feature engineering · padronização sem data leakage · balanceamento de classes



1

Valores perdidos

Verificação completa
(imputação por mediana, se
necessário)

Nenhum valor nulo encontrado



2

Variáveis de Engenharia

4 novas variáveis: so2_ratio,
total_acidity,
alcohol_density_ratio,
sugar_alcohol_ratio

15 features totais, com justificativa
química



3

Split treino/teste

80/20 com stratify=y

914 treino · 229 teste —
proporções preservadas



4

Padronização

Standard Scaler fitado
somente no treino

Sem data leakage



5

Balanceamento

SMOTE (Random Forest) ·
scale_pos_weight (XGBoost)


Classes equilibradas no
aprendizado

MÉTODO

Duas abordagens de balanceamento foram testadas de propósito — oversampling sintético (SMOTE) no Modelo A e ponderação interna de classes no Modelo B — permitindo comparar não apenas algoritmos, mas estratégias completas de tratamento do desbalanceamento.

04 · O Duelo de Modelos

Random Forest vs. XGBoost · GridSearchCV, validação cruzada estratificada (5 folds), scoring = F1



BASELINES — POR QUE OS MODELOS SÃO BONS DE VERDADE

Dummy (classe majoritária) **F1 = 0,000**

Regressão Logística **F1 = 0,483**

XGBoost (recomendado) F1 = 0,657

DECISÃO

XGBoost é o modelo recomendado: vence em Accuracy, Precision, Recall e F1 na classe de interesse e comete menos falsos negativos, dispensando dados sintéticos.

ERROS CRÍTICOS — MATRIZ DE CONFUSÃO

21 / 11

Random Forest — VP / FN


22 / 10

XGBoost — VP / FN

Um vinho bom "desperdiçado" a menos: no contexto de mercado, classificar um vinho bom como comum é o erro mais custoso — e é aí que o XGBoost se destaca.

05 · O Que Torna um Vinho Excelente

Ranking de importância com consenso entre Random Forest e XGBoost (importâncias normalizadas, máx = 1)



CONSISTÊNCIA: as mesmas quatro variáveis lideradas pela correlação na EDA lideram o ranking de importância dos modelos — exploração e modelagem contam a mesma história.

06 · Recomendações para o Processo Produtivo

Três alavancas químicas acionáveis para escalar com sustentabilidade a qualidade superior



R1

Maturação e Fermentação Completas

PROBLEMA

O teor alcoólico é o principal preditor de qualidade — vinhos de alta qualidade têm em média 11,5% vol. contra 10,3% dos comuns.

AÇÃO

Priorizar a maturação adequada das uvas e o controle rigoroso da fermentação, elevando o teor alcoólico natural e o corpo do vinho.



R2

Controle Rigoroso da Acidez Volátil

PROBLEMA

A acidez volátil é o principal marcador de defeito do dataset — em excesso, confere aroma de vinagre e derruba a nota sensorial.

AÇÃO

Monitorar a acidez volátil ao longo de toda a vinificação, evitando contaminação por bactérias acéticas e oxidação descontrolada.



R3

Triagem Laboratorial Automatizada

PROBLEMA

A avaliação sensorial por especialistas é cara, lenta e não escala para todos os lotes.

AÇÃO

Usar o modelo XGBoost como filtro de triagem: priorizar para degustação os lotes com perfil químico de alta qualidade, validando por amostragem.

PRINCÍPIO

O modelo não substitui o enólogo — ele multiplica o alcance do enólogo. A química aponta os lotes promissores com precisão técnica; o especialista confirma e refina. Escala e sustentabilidade para o processo produtivo.

07 · Conclusão

Pipeline completo: EDA → pré-processamento → modelagem → interpretação

PONTOS FORTES IDENTIFICADOS

- ROC-AUC $\approx 0,90$ — boa confiabilidade prevendo alta qualidade apenas com dados físico-químicos
- Superação clara dos baselines (Dummy F1 = 0,000; Reg. Log. F1 = 0,483)
- Consenso entre modelos: álcool, sulfatos, ácido cítrico e acidez volátil dominam
- Interpretação química direta: cada variável tem ação acionável na produção

LIMITAÇÕES E RISCOS

- Dataset restrito a vinhos tintos do Vinho Verde (Portugal) — exige validação adicional
- Classe de alta qualidade com apenas ~159 amostras — limita o recall alcançável
- Variáveis de processo (safra, uva, barrica) não estão no dataset

PRÓXIMOS PASSOS RECOMENDADOS

Alta

Calibração de threshold para priorizar recall

Menos vinhos bons desperdiçados na triagem

Alta

Coleta de mais amostras da classe minoritária

Melhora direta de recall e F1

Média

Interpretabilidade local com SHAP

Explicação lote a lote para o enólogo

Média

Inclusão de variáveis de processo

Novo patamar de desempenho preditivo

“

É possível prever com boa confiabilidade ($ROC-AUC \approx 0,90$) se um vinho tinto será avaliado como de alta qualidade usando apenas suas medidas físico-químicas — e as variáveis que dirigem essa previsão têm interpretação química direta e acionável no processo de produção.

Conclusão Final