

Os Segredos Químicos de um Grande Vinho

Principais insights, ferramentas e resultados da jornada preditiva rumo à qualidade superior

Wine Quality Dataset · Previsão de Qualidade via Química

+0,40

correlação máxima · álcool

~6:1

desbalanceamento de classes

0,657

F1-score · XGBoost

≈ 0,90


ROC-AUC · modelo final

01 · O Desafio e os Dados

1.143 vinhos tintos · 11 variáveis físico-químicas · avaliação sensorial como alvo

A avaliação sensorial de um vinho é cara, demorada e subjetiva. Para transformar essa arte em ciência, a nota de qualidade (0–10, atribuída por enólogos) foi convertida em um problema binário: Alta Qualidade (nota ≥ 7) versus Baixa/Média Qualidade (nota < 7) — o critério consagrado na literatura para este dataset.

Distribuição original da nota (quality)



TRANSFORMAÇÃO BINÁRIA

984

Baixa/Média (nota < 7) — 86,1%

159

Alta Qualidade (nota ≥ 7) — 13,9%

~6:1

Desequilíbrio entre classes — vinhos excelentes são naturalmente raros. Acurácia simples engana; o foco recai sobre F1-score e ROC-AUC.


HIPÓTESES CONFIRMADAS NA EDA

- H1 — Mais álcool → maior qualidade (maturação da uva)
- H2 — Mais acidez volátil → menor qualidade (aroma de vinagre)
- H3 — Sulfatos adequados → melhor conservação e qualidade

Dataset 100% completo — nenhum valor nulo em 1.143 x 12 colunas

02 · O Que Determina um Bom Vinho

Correlação de Pearson de cada variável físico-química com a Alta Qualidade (*high_quality*)



LEITURA DO RANKING

Álcool (+0,40)

Correlação mais forte — uvas maduras, mais corpo.

Acidez volátil (-0,30)

Principal marcador de defeito — aroma de vinagre.

Ácido cítrico (+0,25)

Frescor e equilíbrio de sabor.


Sulfatos (+0,21)

Conservação e estabilidade do vinho.

Multicolinearidade monitorada: fixed acidity ↔ citric acid (+0,67), fixed acidity ↔ pH (-0,69), alcohol ↔ density (-0,49) — informação parcialmente redundante entre variáveis de acidez e densidade.

02.1 · Perfil Químico Comparado

Médias das 4 variáveis mais determinantes — Comum (nota < 7) vs. Alta Qualidade (nota ≥ 7)



Álcool

+12%

Principal preditor de qualidade

Acidez volátil

-29%

"Inimiga" da qualidade — aroma de vinagre

Sulfatos

+16%

Conservação e estabilidade

Ácido cítrico

+57%

Frescor e vivacidade

O teor alcoólico é praticamente monotônico com a nota: da 5 em diante, cada ponto acima acompanha mais álcool médio — e menos acidez volátil.

03 · Ferramentas e Metodologia

Stack técnico utilizado do dado bruto ao modelo final — Google Colab, Python e bibliotecas especializadas



pandas & numpy

Manipulação e estruturação dos dados tabulares



matplotlib & seaborn

Visualizações da EDA — histogramas, boxplots, correlação



scikit-learn

StandardScaler, train_test_split, GridSearchCV, Random Forest, Regressão Logística



imbalanced-learn (SMOTE)

Oversampling sintético da classe minoritária no Modelo A



XGBoost

Gradient boosting com scale_pos_weight no Modelo B




joblib

Serialização dos modelos e do scaler para produção

PIPELINE: EDA → Pré-processamento → Modelagem (RF + XGBoost) → Avaliação → Interpretação

04 · O Duelo de Modelos

Random Forest (SMOTE) vs. XGBoost (scale_pos_weight) · GridSearchCV, 5 folds, scoring = F1



BASELINES DE REFERÊNCIA

Dummy (classe majoritária)

F1 = 0,000

Regressão Logística

F1 = 0,483

Random Forest

F1 = 0,627

XGBoost (recomendado)

F1 = 0,657

DECISÃO

XGBoost vence em 4 das 5 métricas e comete menos falsos negativos, dispensando dados sintéticos.

ERROS CRÍTICOS — MATRIZ DE CONFUSÃO

21 / 11

Random Forest — VP / FN

22 / 10

XGBoost — VP / FN

O XGBoost classifica corretamente 1 vinho bom a mais — o erro mais custoso no contexto de mercado é deixar passar um vinho de alta qualidade.

05 · Resultado Final Resumido

XGBoost como modelo recomendado — desempenho, consenso de variáveis e leitura prática

0,900	0,629	0,688	0,657	0,900
Accuracy	Precision	Recall	F1-score	ROC-AUC

VARIÁVEIS DE CONSENSO ENTRE OS DOIS MODELOS

1	<i>alcohol</i>	Principal determinante em ambos os modelos
2	<i>sulphates</i>	Segunda variável mais importante nos dois
3	<i>volatile acidity</i>	Presença forte nos dois rankings de importância

RECOMENDAÇÃO FINAL

O XGBoost é o modelo indicado para produção: F1 = 0,657 e Recall = 0,688 na classe de interesse, alcançados sem oversampling sintético — apenas ajuste de peso interno (`scale_pos_weight = 6,2`).

A química aponta os lotes promissores com precisão técnica; o especialista confirma e refina — escala e sustentabilidade para a produção.

“

Álcool, acidez volátil, ácido cítrico e sulfatos contam a mesma história em toda a análise — da correlação na EDA ao consenso entre dois algoritmos distintos. A química, quando bem lida, prevê a qualidade com boa confiabilidade ($ROC-AUC \approx 0,90$).

Conclusão Final