

Relatório Executivo

A Ciência por Trás de um Grande Vinho
Wine Quality Dataset · Previsão de Qualidade via Química
Tech Challenge · Fase 2 · 13DTA · Grupo 14 · Julho 2026

1.143 Amostras Analisadas	13,9% Vinhos de Alta Qualidade	0,657 F1-score · XGBoost	≈ 0,90 ROC-AUC · Modelo Final
------------------------------	-----------------------------------	-----------------------------	----------------------------------

1. Contexto e Base de Dados

Wine Quality Dataset · Vinhos tintos · 11 variáveis físico-químicas

A avaliação sensorial de um vinho é tradicionalmente cara, demorada e subjetiva, dependendo do paladar de especialistas treinados. Este trabalho transforma essa arte em ciência: a partir do **Wine Quality Dataset** (1.143 amostras de vinho tinto, cada uma com 11 variáveis físico-químicas medidas em laboratório), construímos modelos de Machine Learning capazes de prever se um vinho será classificado como de **Alta Qualidade** (nota ≥ 7) ou **Baixa/Média Qualidade** (nota < 7).

1.1 Escopo da Análise

1.143 Amostras Carregadas	11 + 4 Features Originais + Engineered	159 Vinhos Nota ≥ 7	80 / 20 Split Treino / Teste
------------------------------	--	------------------------	---------------------------------

1.2 Dimensões Investigadas

- Análise Exploratória (EDA)** — distribuições, outliers e correlações entre química e qualidade
- Pré-processamento** — feature engineering, padronização sem data leakage e balanceamento de classes
- Duelo de Modelos** — Random Forest (com SMOTE) vs. XGBoost (com scale_pos_weight), ambos otimizados via GridSearchCV
- Interpretação** — ranking de importância das variáveis com consenso entre os dois modelos
- Implicações Práticas** — recomendações acionáveis para o processo produtivo da vinícola

INSIGHT	Apenas 13,9% das amostras são de alta qualidade — um problema clássico de classificação desbalanceada (~6:1). Toda a estratégia de modelagem foi desenhada em torno desse desafio, priorizando F1-score e recall da classe minoritária em vez da acurácia bruta.
---------	--

01 O Que os Dados Revelaram (EDA)

1.143 amostras · notas de 3 a 8 · dataset completo, sem valores nulos

2.1 Perfil Químico do Vinho de Alta Qualidade

A análise exploratória confirmou hipóteses fundamentais da enologia. Comparando as médias das variáveis entre as duas classes, quatro indicadores formam um perfil químico claro do vinho de alta qualidade: **mais álcool, mais sulfatos, mais ácido cítrico e menos acidez volátil**.

Variável	Comum (nota < 7)	Alta (nota ≥ 7)	Variação	Diagnóstico
Álcool (% vol.)	10,27	11,53	+12%	• Principal preditor de qualidade
Acidez volátil (g/L)	0,55	0,40	-29%	• "Inimiga" da qualidade — aroma de vinagre

Sulfatos (g/L)	0,64	0,75	+16%	• Conservação e estabilidade
Ácido cítrico (g/L)	0,25	0,39	+57%	• Frescor e vivacidade

2.2 Conclusões da Exploração

- Dataset completo, **sem valores nulos** — pré-processamento simplificado
- Classes fortemente desbalanceadas (**~85% vs ~15%**) — exigiu métricas e técnicas específicas
- 'alcohol', 'volatile acidity', 'sulphates' e 'citric acid' são as variáveis mais correlacionadas com a qualidade
- Outliers relevantes em 'residual sugar' e nos dióxidos de enxofre, tratados no pré-processamento
- Correlação alta (~0,67) entre SO2 livre e total — potencial multicolinearidade monitorada na modelagem

DIAGNÓSTICO

O teor alcoólico é praticamente monotônico em relação à nota: da nota 5 em diante, cada ponto adicional de qualidade acompanha um aumento no álcool médio. A acidez volátil apresenta o comportamento espelhado — cai de forma consistente conforme a nota sobe.

02 Preparando o Terreno (Pré-processamento)

Feature engineering · Padronização sem data leakage · Balanceamento de classes

Etapa	Técnica Aplicada	Resultado
Missing values	Verificação completa (imputação por mediana, se necessário)	• Nenhum valor nulo encontrado
Feature engineering	4 novas variáveis: so2_ratio, total_acidity, alcohol_density_ratio, sugar_alcohol_ratio	15 features totais com justificativa química
Split treino/teste	80/20 com stratify=y	914 treino · 229 teste, proporções preservadas
Padronização	StandardScaler fitado somente no treino	• Sem data leakage
Balanceamento	SMOTE (Random Forest) · scale_pos_weight (XGBoost)	Classes equilibradas no aprendizado

MÉTODO

Duas abordagens de balanceamento foram testadas de propósito: oversampling sintético (SMOTE) no Modelo A e ponderação interna de classes no Modelo B. Isso permitiu comparar não apenas algoritmos, mas estratégias completas de tratamento do desbalanceamento.

03 O Duelo de Modelos

Random Forest vs. XGBoost · GridSearchCV com validação cruzada estratificada (5 folds) · scoring = F1

3.1 Comparação de Métricas — Conjunto de Teste

Métrica	Random Forest (A)	XGBoost (B)	Vencedor
Accuracy	0,891	0,900	XGBoost (+0,9 p.p.)
Precision (classe Alta)	0,600	0,629	XGBoost (+2,9 p.p.)
Recall (classe Alta)	0,656	0,688	XGBoost (+3,2 p.p.)
F1-score (classe Alta)	0,627	0,657	XGBoost (+3,0 p.p.)
ROC-AUC	0,918	0,900	Random Forest (+1,8 p.p.)

3.2 Baselines — Por que os Modelos São Bons de Verdade

Ambos os modelos superam com folga os baselines estabelecidos: o classificador Dummy (sempre classe majoritária) obtém **F1 = 0,000** na classe de interesse — evidenciando a armadilha da acurácia em dados desbalanceados — e a Regressão Logística alcança apenas **F1 = 0,483**. Isso confirma que as variáveis físico-químicas carregam informação preditiva real sobre a qualidade sensorial.

3.3 Erros Críticos — Matriz de Confusão

Modelo	Verdadeiros Positivos	Falsos Negativos	Leitura
--------	-----------------------	------------------	---------

Random Forest	21	11	• Bom desempenho geral
XGBoost	22	10	• Um vinho bom "desperdiçado" a menos

DECISÃO	O XGBoost é o modelo recomendado: vence em Accuracy, Precision, Recall e F1-score na classe de interesse, comete menos falsos negativos (10 vs 11) e dispensa a geração de dados sintéticos — apenas ajusta pesos internos via <code>scale_pos_weight</code> . No contexto de mercado, classificar um vinho bom como comum é o erro mais custoso, e é exatamente aí que o XGBoost se destaca.
---------	---

04 O Que Torna um Vinho Excelente

Ranking de importância com consenso entre os dois modelos (importâncias normalizadas, máx = 1)

Para reduzir o risco de conclusões enviesadas por um único algoritmo, as importâncias de cada modelo foram normalizadas e combinadas em um consenso. Apesar de arquiteturas e pipelines diferentes, os dois modelos convergem para o mesmo grupo de variáveis dominantes:

#	Variável	Efeito	Interpretação Química
1	alcohol	• Positivo (forte)	Uvas mais maduras e fermentação completa — corpo e estrutura ao vinho. Importância = 1,00 nos dois modelos.
2	sulphates	• Positivo	Ação antioxidante e antimicrobiana; protege da deterioração e preserva o aroma.
3	citric acid	• Positivo	Frescor e vivacidade; vinhos de alta qualidade têm ~57% mais ácido cítrico em média.
4	volatile acidity	• Negativo (forte)	Em excesso remete a vinagre (ácido acético) — defeito sensorial clássico. Alta qualidade tem ~29% menos.

CONSISTÊNCIA	As mesmas quatro variáveis apontadas pela análise de correlação na EDA lideram o ranking de importância dos modelos — a análise exploratória e a modelagem contam a mesma história. No Modelo A, a feature engineered <code>alcohol_density_ratio</code> aparece em 2º lugar, reforçando o papel central do álcool.
--------------	---

05 Recomendações para o Processo Produtivo

Três alavancas químicas acionáveis, priorizadas pelo impacto previsto nos modelos

R1 — Maturação e Fermentação Completas	
Problema: O teor alcoólico é o principal preditor de qualidade — vinhos de alta qualidade têm em média 11,5% vol. contra 10,3% dos comuns. Ação: Priorizar a maturação adequada das uvas e o controle rigoroso da fermentação, elevando o teor alcoólico natural e o corpo do vinho.	
R2 — Controle Rigoroso da Acidez Volátil	
Problema: A acidez volátil é o principal marcador de defeito do dataset — em excesso, confere aroma de vinagre e derruba a nota sensorial. Ação: Monitorar a acidez volátil ao longo de toda a vinificação, evitando contaminação por bactérias acéticas e oxidação descontrolada.	
R3 — Triagem Laboratorial Automatizada com o Modelo	
Problema: A avaliação sensorial por especialistas é cara, lenta e não escala para todos os lotes. Ação: Usar o modelo XGBoost como filtro de triagem: priorizar para degustação os lotes com perfil químico de alta qualidade, validando por amostragem e readequando o modelo de forma ágil.	
PRINCÍPIO	O modelo não substitui o enólogo — ele multiplica o alcance do enólogo. A química aponta os lotes promissores com precisão técnica; o especialista confirma e refina. Escala e sustentabilidade para o processo produtivo.

06 Conclusão

Pipeline completo: EDA → pré-processamento → modelagem → interpretação

6.1 Pontos Fortes Identificados

- **ROC-AUC ≈ 0,90:** é possível prever com boa confiabilidade a alta qualidade usando apenas medidas físico-químicas
- **Superação clara dos baselines** (Dummy F1 = 0,000; Regressão Logística F1 = 0,483): informação preditiva real
- **Consenso entre modelos:** álcool, sulfatos, ácido cítrico e acidez volátil dominam nos dois algoritmos
- **Interpretação química direta:** cada variável importante tem ação acionável no processo de produção

6.2 Limitações e Riscos

- Dataset restrito a **vinhos tintos de uma região específica** (Vinho Verde, Portugal) — generalização exige validação adicional
- Classe de alta qualidade com apenas **~159 amostras** — limita o recall alcançável; mais dados tendem a melhorar o modelo
- Variáveis de processo (safra, uva, barrica) **não estão presentes** no dataset e poderiam elevar o desempenho

6.3 Próximos Passos Recomendados

Prioridade	Ação	Impacto Esperado
Alta	Calibração de threshold para priorizar recall	Menos vinhos bons desperdiçados na triagem
Alta	Coleta de mais amostras da classe minoritária	Melhora direta de recall e F1
Média	Interpretabilidade local com SHAP	Explicação lote a lote para o enólogo

Média	Modelos de regressão ordinal (escala 3–8 original)	Aproveitamento total da granularidade das notas
Média	Inclusão de variáveis de processo (safra, uva, barrica)	Novo patamar de desempenho preditivo
CONCLUSÃO FINAL	É possível prever com boa confiabilidade (ROC-AUC $\approx$ 0,90) se um vinho tinto será avaliado como de alta qualidade usando apenas suas medidas físico-químicas — e as variáveis que dirigem essa previsão têm interpretação química direta e acionável no processo de produção.	

07 Materiais e Links do Projeto

Apresentação · Notebook · Repositório · Apresentação Executiva

Todos os artefatos produzidos pelo Grupo 14 neste Tech Challenge estão disponíveis nos links abaixo: vídeo de apresentação, notebook completo com o pipeline de Machine Learning, código-fonte versionado e a apresentação executiva do projeto.

Apresentação

Vídeo de apresentação do projeto (YouTube)

<https://youtu.be/yx3-ENmUQ1E>

Google Colab

Notebook completo: EDA, pré-processamento, modelagem e interpretação

<https://colab.research.google.com/drive/1Hxkop3J1CpPzaZNSd-wZcnp2A4LLjRZi?authuser=1>

Repositório GitHub

Código-fonte do projeto · Pos-Tech-13DTA-Grupo14 / tech-challenge-fase2

<https://github.com/Pos-Tech-13DTA-Grupo14/tech-challenge-fase2>

Apresentação Executiva

Pasta no Google Drive com a apresentação executiva do projeto

<https://drive.google.com/drive/u/1/folders/1RvyEGo9GWtGJyaS9kbbeBobueV4GV91o>